SYSTEM · DECISION · INCIDENT ARCHIVE

복잡한 시스템을 단순하게,
서비스는 더 안정적으로.

서비스 구조 설계부터 성능 개선, 인증 통합, 배포와 장애 복구까지
맡아온 3년 9개월차 소프트웨어 엔지니어 고지훈입니다.

성능 최적화	인증 · 권한 설계	인프라 · 배포 자동화	운영 안정성
쿼리 튜닝 · 병목 분석	SSO 통합 · 접근 제어	Kubernetes · GitOps	장애 복구 · 재발 방지

웹 포트폴리오에서 프로젝트별 상세 설명과 기술적 의사결정 과정을 살펴보세요.
emibgo2.github.io/portfolio-site

01 소개 about

서비스의 병목과 운영의 비효율을 찾아 개선하는 백엔드 개발자입니다.
쿼리 최적화부터 처리 구조 개선, 배포·복구 자동화까지 필요한 영역을 직접 다뤄왔습니다.
성능과 비용, 유지보수성을 함께 고려하며 팀이 안정적으로 서비스를 개발하고 운영할 수 있는 기반을 만듭니다.

경력

메디컬아이피
2025.06 – 현재

- DB 설계 및 개선
- 인프라 개선
- 성능 최적화 및 유지보수
- 클라우드 운영 및 관리

네모시스
2023.02 – 2025.05

- 소프트웨어 설계 및 개발
- ERD 및 DB 설계
- 성능 최적화 및 유지보수
- 클라우드 운영 및 관리

피플 · 코파운더
2022.02 – 2023.11

- 공동 창업 및 서비스 기획
- DB 설계
- 앱 개발

활동 · 수상 · 학력

- 토스 Learner's High 1기 (2024.12 – 2025.01) —
  토스 개발자 멘토링에서 커리어 점검과 실무 개선 과제 수행
- 2022 한이음 공모전 한국정보산업연합회
  회장상 수상 (과학기술정보통신부)
- 2022 신한 스퀘어 브릿지 대학생 부문 우수상 수상
- 철도 시설물 성능평가 관련 프로그램 특허 출원 경험
- 피플(헌혈 매칭 플랫폼) 창업 및 2023
  예비사회적 기업 선정 (서비스 수익화 경험)
- 평택대학교 융합소프트웨어학과 졸업 (4.27 / 4.5)

01 파일 데이터센터 성능 개선 및 비동기 처리 아키텍처 구축

MedicalIP 설계 · 구축 · 성능 검증

> 소수 사용자의 대량 파일 업로드 속도를 높이고, 검증·DB 연결
> 부하를 제어해 안정적인 처리 구조를 만들었습니다.

문제

소수 사용자가 수만~수십만 개 파일을 올려 총량이 TB 규모에 이르는 환경으로, **각 사용자의 대량 업로드를 빠르고 안정적으로 마치는 것**이 핵심 과제였습니다. 전송·검증·메타데이터 조회가 같은 자원을 사용하면서 스레드와 DB 커넥션을 오래 점유해, 업로드 처리량뿐 아니라 일반 API 응답에도 부담이 생겼습니다.

판단

Presigned URL을 통한 스토리지 직접 전송을 바탕으로, **전송과 검증·후처리의 부하를 분리하고 워커 확장이 노드·DB 과부하로 이어지지 않도록** 설계했습니다. 전송 동시성은 AIMD로 조절하되 개선 효과는 전송 구간과 검증·마무리를 포함한 전체 완료 시간을 구분해 측정했습니다.

비동기 처리

파일 검증·후처리를 Kafka 이벤트를 받는 비동기 워커로 옮겨 **백엔드 요청 경로에서 분리**했습니다. RabbitMQ 등과 비교할 때 대량 이벤트 처리 성능에 더해 **Kafka Connect·Streams·CDC를 활용한 사내 데이터 파이프라인 확장성**까지 고려한 선택이었습니다.

워커 확장

Pod가 0개인 상태에서 여러 워커를 동시에 기동하자 노드 부하가 급증해, **기본 Pod 2~3개를 유지하고 작업이 밀릴 때 추가 확장**하는 방식으로 바꿨습니다. KEDA가 Kafka Consumer Lag(소비 지연 메시지 수)을 기준으로 워커를 늘리도록 하면서, 작업 크기와 워커별 동시 실행 수도 제한해 확장 시 부하를 관리했습니다.

연결 관리

워커가 늘어날 때 DB 연결 요청도 함께 증가하므로, **API와 워커의 연결 경로를 분리하고 워커 연결은 PgBouncer를 거치도록** 구성했습니다. 연결 풀링으로 커넥션 부담을 낮추는 동시에 메타데이터 조회 범위와 인덱스를 조정해 DB가 처리해야 할 작업도 줄였습니다.

결과

전송·검증·DB 연결의 부하를 나누고 워커 확장 정책을 조정해 대량 업로드가 노드와 DB에 주는 부담을 줄였습니다. 별도로 진행한 72.94GB·150,205개 입력 파일의 AIMD 적용 전후 비교에서는 고정 동시 요청 100개 대비 업로더 실행 시간이 **22분 18.0초에서 15분 28.3초로 단축**됐고, 입력 용량 기준 평균 처리량은 54.5 MB/s에서 78.6 MB/s로 늘면서 재시도는 3,574회에서 187회로 감소했습니다.

검증 성능

2026년 7월 초기 검증 파이프라인을 **5.37GB·10,636개 파일**로 측정한 결과, 파일 선언 18.8초·전송 34.9초·검증 216.9초로 **전체 완료까지 270.7초 (4분 30.7초)**가 걸렸으며 10,636개 파일 모두 검증에 성공했습니다.

업로드 성능

2026년 8월 **72.94GB(67.93GiB)·150,205개 입력 파일** 비교에서 AIMD 파일 전송 구간은 927.7초였고, 스캔·제어 요청·전송·재시도·마무리를 포함한 업로더 전체 실행 시간은 928.3초였습니다. 입력 용량을 전체 실행 시간으로 나눈 **평균 처리량은 78.6 MB/s**였으며, 업로드 완료 149,897건과 재시도 187회를 기록했습니다.

TB 규모	**Pod 2~3개**	**22분 18초 → 15분 28초**
수만~수십만 개 파일의 총 업로드량	상시 유지 · 대기량에 따라 추가 확장	72.94GB 입력 · 업로더 실행 · 2026.08

도식 1 파일 검증·후처리를 요청 처리와 어떻게 분리했는가?



Kafka로 파일 처리 이벤트를 전달하고, 비동기 워커에서 검증·후처리를 실행합니다.

도식 2 검증 처리량을 늘려도 노드와 DB가 과부하되지 않게 하려면?

KEDA — 검증 처리 용량 확보 + 노드 부하 제어

Pod 0개에서 동시 기동할 때 발생한 노드 부하 급증을 줄였습니다.

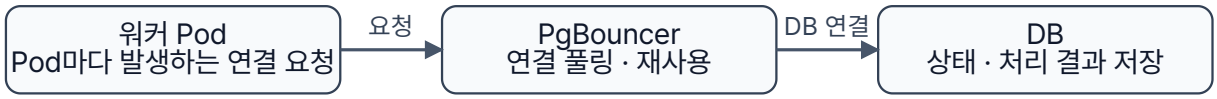


기본 Pod 2~3개를 유지해 파일 수신 이벤트와 대기 작업을 처리합니다.

작업 크기와 워커별 동시 실행 수를 제한해 확장 시 자원 사용을 관리합니다.

PGBOUNCER — 워커 확장에 따른 DB 연결 부하 제어

Pod가 늘 때 함께 증가하는 DB 연결 요청을 커넥션 풀링으로 완화했습니다.



API와 워커의 DB 연결 경로를 분리하고, 워커 연결은 PgBouncer를 거치게 했습니다.

처리 Pod를 유연하게 늘리면서도 DB 커넥션 증가 부담을 함께 줄였습니다.

Kafka 기반 검증·후처리 워커는 KEDA로 처리 용량을 늘리고, PgBouncer로 DB 연결 부담을 줄였습니다.

Presigned URL | S3 호환 스토리지 | Kafka | KEDA | PgBouncer | Transactional Outbox | 비동기 워커 | 부하 테스트

02 사내 SSO 시스템 구축

MedicalIP 2026.02 – 2026.03 · 약 2개월 설계 · 구축

> Keycloak 기반 SSO로 반복 로그인을 줄이고, 사내 시스템의 접근 권한·세션 관리를 중앙화했습니다.

문제 시스템마다 로그인·세션 기준이 다르고 계정 생성과 회수도 각 도구에서 수동으로 처리하다 보니, 반복 로그인뿐 아니라 **퇴사자의 접근 권한이 남아 있어도 알아차리기 어려운 문제**가 있었습니다.

판단 자체 인증 모듈로 Sentry·Rancher·VPN 같은 외부 솔루션까지 연결하기에는 제약이 있어, 표준 인증 프로토콜을 지원하고 인증 정책을 중앙에서 관리할 수 있는 Keycloak을 선택했습니다.

실행 기존 업무 계정을 그대로 사용할 수 있도록 Naver Works를 IdP로 연결하고, Keycloak·Spring Security·Gateway와 OAuth2/OIDC를 기반으로 Admin Console·Sentry·Rancher·VPN의 인증을 통합했습니다.
접근 권한과 세션 정책을 공통으로 관리하면서 **권한 판단 기준을 역할에서 속성으로 전환**했으며(RBAC → ABAC), 로그인과 주요 시스템 접근에는 MFA를 적용했습니다.
인증 서비스의 가용성은 Keycloak 분산 배포로 보완했습니다.

결과 기존 업무 계정으로 한 번 로그인하면 여러 사내 시스템을 이용할 수 있어 **업무 도구를 오갈 때 반복 로그인하는 불편이 줄었고**, 각 시스템에 흩어져 있던 접근 권한과 세션 정책도 한곳에서 관리할 수 있게 됐습니다.

통합 로그인	MFA	ABAC
Keycloak SSO · 사내 시스템 접근	로그인 · 주요 접근	역할 → 속성 기반

도식 1 **KEYCLOAK 로그인은 사내 시스템 접근으로 어떻게 이어지는가?**



권한은 역할이 아니라 속성으로 판단합니다 (RBAC → ABAC). 도구가 늘어나도 권한 판단 기준은 하나입니다.

외부 IdP의 계정 인증으로 Keycloak에 로그인하고, Keycloak의 SSO를 통해 사내 시스템에 접근합니다.

Keycloak | OAuth2/OIDC | Spring Security | ABAC | MFA

03 온프레미스 Kubernetes 및 DR 환경 구축

MedicalIP 2025.11 – 2026.02 · 약 4개월 설계 · 구축 · 운영

> 사내 유휴 장비로 Kubernetes 운영 환경을 구축해 AWS 비용을 줄이고,
> 배포·모니터링·트래픽 제어와 재해 복구(DR) 체계를 정비했습니다.

문제

기존 Docker Swarm 환경은 환경마다 설정이 다르고 배포 기록도 운영 채널에 남지 않아 변경 이력을 추적하기 어려웠습니다.
AWS 운영 비용을 줄이면서 배포·모니터링·트래픽 제어도 함께 정비해, 비용과 운영 관리의 부담을 줄이는 것이 이번 전환의 과제였습니다.

판단

트래픽 변동이 크지 않고 사내 유휴 장비를 활용할 수 있어, **운영 워크로드는 온프레미스로 옮기고 AWS는 장애에 대비한 DR 용도로 축소**하는 방향을 잡았습니다.

전환 이유

운영 플랫폼은 **ArgoCD 기반 GitOps, Prometheus·Loki 모니터링, Istio·Gateway API 트래픽 제어를 함께 구성할 수 있는 Kubernetes**로 전환했습니다.
배포 설정과 운영 정책을 선언형 리소스로 관리하면서, Operator로 반복되는 설정도 자동화할 수 있다는 점을 고려한 선택이었습니다.

구축·운영

유휴 장비 9대에 RKE 클러스터를 구축해 Rancher로 관리하면서 AWS 워크로드를 이관하고, **NAS 17대를 PV(PersistentVolume)로 연결**해 영속 스토리지로 활용했습니다.
배포는 ArgoCD App of Apps와 Image Updater로 자동화해 결과와 상태가 Teams에 남도록 연결했으며, kube-prometheus-stack과 Loki로 메트릭·로그 수집과 알림 체계도 갖췄습니다.
트래픽은 Istio·Gateway API의 **헤더 기반 카나리 배포**로 beta(스테이징) 환경을 구분하고, Kiali로 서비스 간 흐름을 확인하는 방식으로 관리했습니다.

DR 구성

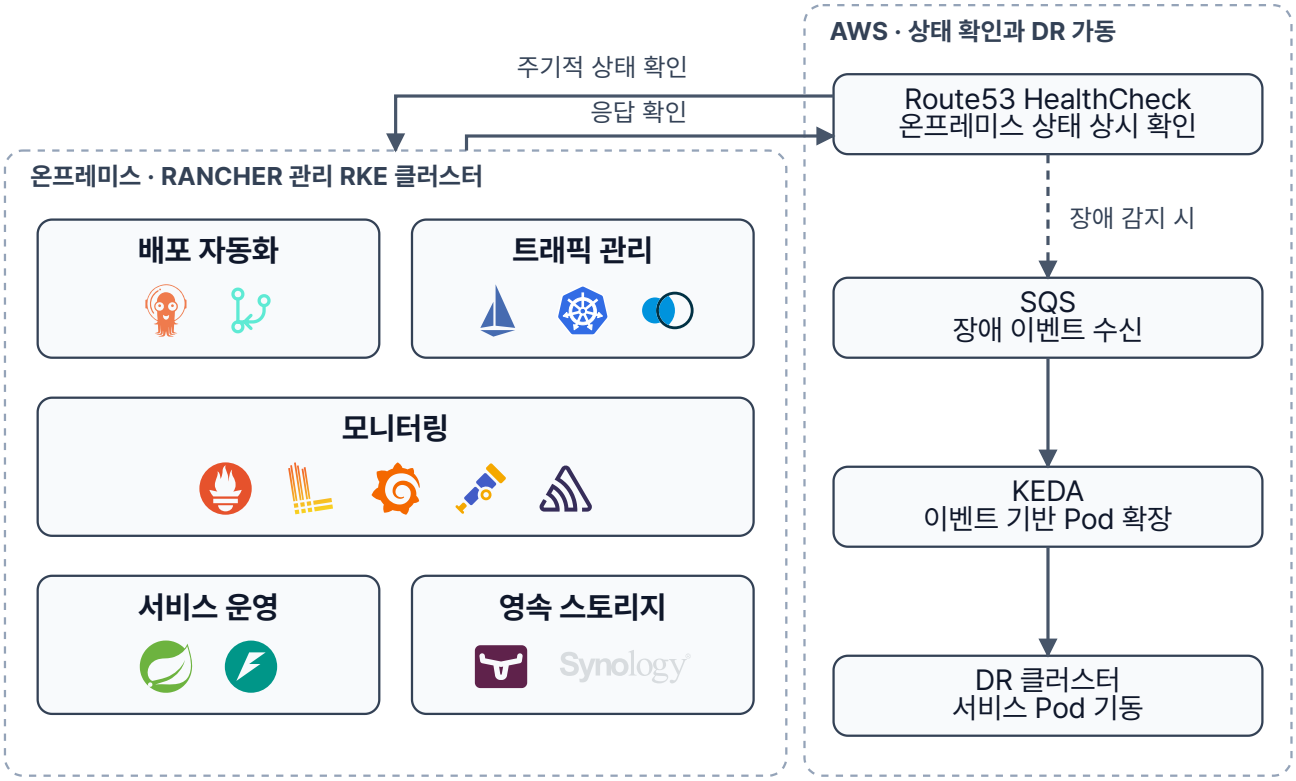
온프레미스 장애에 대비해 AWS에 복구 환경을 마련하고, Route53 HealthCheck의 감지 이벤트가 SQS로 전달되면 **KEDA가 DR 클러스터의 서비스 Pod를 자동으로 기동**하도록 연결했습니다.
구성한 복구 경로는 DB Replication과 함께 시나리오로 정리해 정기 DR 훈련에서 검증했습니다.

결과

전환 이후 **AWS 월 비용은 2026년 1월 $448.19에서 9월 $46.22로 89.7% 감소**했고, EC2 서비스 요금도 같은 해 1월 $238.98에서 7월 $9.03로 줄었습니다.
배포 변경 이력과 롤백 기준은 Git에, 배포 상태는 Teams에 남아 추적이 쉬워졌으며, 메트릭 모니터링과 로그 수집 자동화로 **이슈 대응 속도도 두 배로 높아졌습니다.**

89.7%↓	**$46.22**	**9대**
AWS 월 비용 · 2026.01 → 09	2026.09 월 비용	유휴 컴퓨팅 장비 활용

도식 1 온프레미스 장애가 나면 DR은 어떻게 가동되는가?



Route53 HealthCheck가 온프레미스 상태를 주기적으로 확인합니다.
장애가 감지되면 SQS 이벤트를 받아 KEDA가 DR 클러스터의 서비스 Pod를 기동합니다.

도식 2 배포는 어떤 순서로 흐르는가?



변경 추적과 일관된 배포

배포 설정을 Git으로 관리해 무엇이 바뀌었는지 추적하고, ArgoCD로 클러스터에 일관되게 반영합니다.
문제가 생기면 Git의 배포 설정을 이전 버전으로 되돌려, 같은 배포 절차로 복구할 수 있습니다.

Git을 배포 상태의 기준으로 삼아 변경 이력 추적과 반복 가능한 배포·복구가 가능해졌습니다.
배포 완료·상태 알림은 Teams에 남습니다.

Kubernetes | RKE | Rancher | ArgoCD | Istio | Gateway API | KEDA | Longhorn | AWS | 비용 최적화

04 라이선스 서버 재설계

MedicalIP 2025.08 – 2025.10 · 약 3개월 설계 · 개발

> 라이선스 정책을 DB로 분리해 배포 없이 조정하고,
> 정책 조회 시간을 800ms에서 400ms로 줄였습니다.

문제 상품별 라이선스 제한 정책이 코드에 흩어져 있어 변경할 때마다 수정과 배포가 필요했고, 실행 순서와 실패 처리 기준까지 뒤섞여 **같은 라이선스에도 사용자마다 다른 제한이 적용되는 문제**가 생겼습니다.

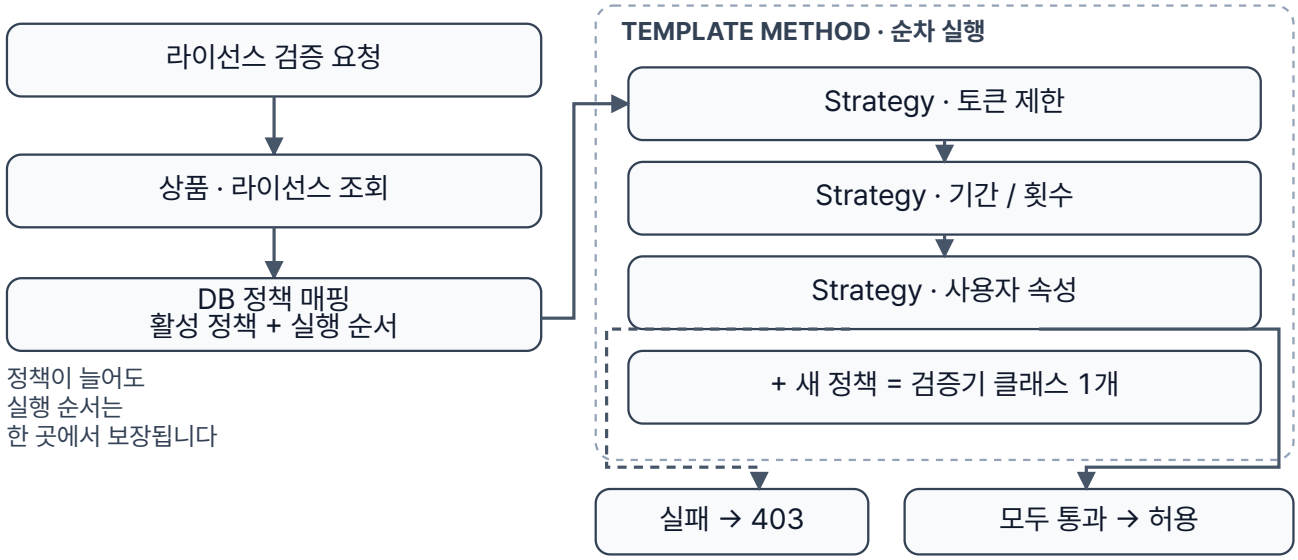
판단 룰 엔진 도입에 필요한 학습 비용과 운영자의 관리 부담이 정책 규모에 비해 크다고 판단해, 정책 데이터는 DB에 두고 검증 실행 흐름은 코드로 관리하는 단순한 구성을 선택했습니다.

실행 상품별 활성 정책과 적용 순서는 DB에서 조정하도록 옮기고, 정책 타입별 검증 책임은 Strategy로 분리했습니다. 공통 실행과 실패 처리는 Template Method로 모아 **어느 정책에서든 검증이 실패하면 403으로 차단**하도록 통일하고, 핵심 API는 Unit·Integration·E2E 테스트로 검증했습니다.

결과 정책 조합을 바꿀 때마다 배포하던 과정을 없애고, 새 정책도 검증기 클래스 하나로 추가할 수 있게 했습니다. DB 설계를 함께 개편하면서 **평균 정책 조회 시간은 800ms에서 400ms로 줄였으며**, 핵심 API 테스트 커버리지 80%를 확보했습니다.

800ms → 400ms	80%	클래스 1개
정책 조회	핵심 API 커버리지	신규 정책 추가 비용

도식 1 어디까지 코드가 하고, 어디부터 데이터가 하는가?



운영자가 바꾸는 영역(정책 데이터)과 개발자가 책임지는 영역(실행 순서 · 실패 처리)을 분리했습니다.

Kotlin | Spring | JPA | MariaDB | Junit5 | Strategy Pattern

05

NDRS · 재해 복구 시스템

Nemosys 2024.11 – 2025.01 · 약 2개월 설계 · 개발

> 장애 감지와 복구를 자동화해 복구 시간을 10분에서 3분 이내로 줄였습니다.

문제 온프레미스 메인 서버가 불안정한 전원 공급으로 간헐적으로 중단되는 데다 복구도 사람의 판단에 의존해, **대응자가 자리에 있는지에 따라 복구 시간이 달라졌습니다.**

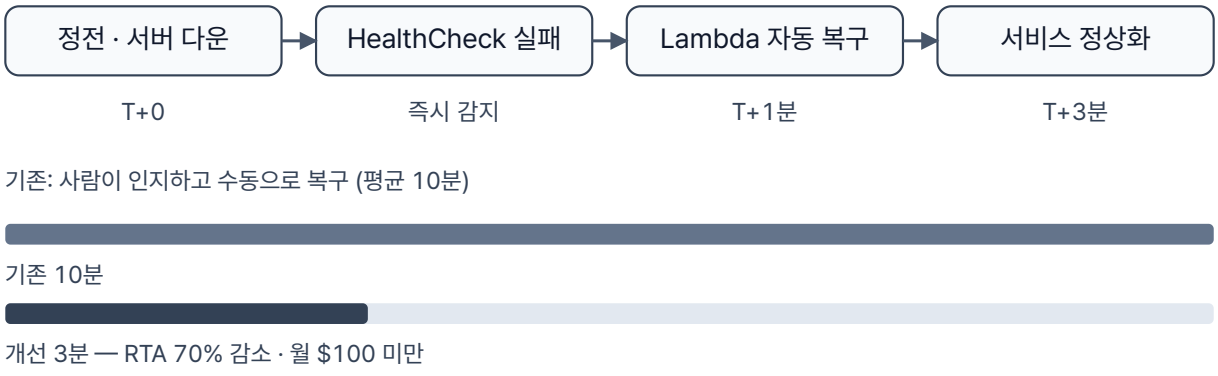
판단 월 100달러 미만의 비용과 3분 이내 복구를 설계 기준으로 삼고, 기존 온프레미스 운영을 유지하면서 최소한의 클라우드 자원으로 장애 감지와 전환을 자동화하는 방향을 잡았습니다.

실행 AWS EC2 기반 DB Active-Standby를 구성하고, Route53 HealthCheck·CloudWatch에서 감지한 이상을 EventBridge 이벤트로 전달했습니다. 이 이벤트가 **Lambda·Step Functions의 인스턴스 복구와 Lambda의 DNS IP 전환**으로 이어지도록 연결했으며, 복구 경로는 코드로 관리하고 주기적으로 검증할 절차도 마련했습니다.

결과 장애 감지부터 인스턴스 복구·DNS 전환까지 자동화하면서 **복구 시간을 10분에서 3분 이내로 줄였고(RTA 70% 감소)**, 월 100달러 미만으로 재해 복구 체계를 마련했습니다.

10분 → 3분	**70%↓**	**< $100**
복구 시간	RTA 감소	월 비용

도식 1 장애 복구는 몇 분 안에, 누가 하는가?



장애 감지부터 복구까지 자동화해 평균 복구 시간을 10분에서 3분으로 줄였습니다.

AWS · Route53 · EventBridge · Lambda · Step Functions

06

테스트 코드 문화 도입 및 CI 파이프라인

Nemosys 2024.12 – 2025.01 · 약 2개월 주도 · 세미나

> 팀 내 테스트 기준을 정립하고, MR·Merge 후 단계별 자동 검증을 CI에 도입했습니다.

문제

테스트 코드가 없는 상태에서 기능을 바꿀 때마다 회귀 오류가 발생했고, 수동으로 확인할 범위도 늘어나 **새 기능 개발과 배포 품질 확인에 드는 부담**이 함께 커졌습니다.

판단

팀이 테스트를 개발 과정에서 활용할 수 있도록 세미나를 주도해 E2E·Integration·Unit의 역할과 회귀 오류 예방 사례를 공유하고, 공통 테스트 기준과 자동 검증 환경을 함께 마련하는 데 집중했습니다.

실행

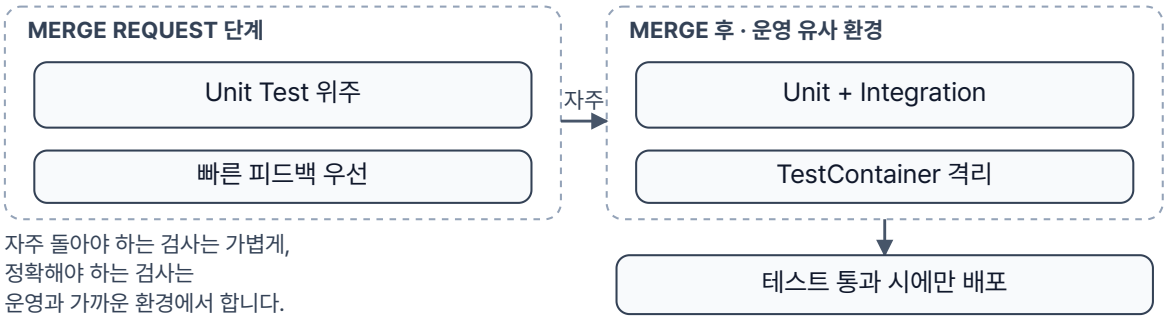
Testcontainers와 테스트용 DB로 격리 환경을 마련한 뒤 GitLab Runner·Jenkins의 CI에 연결하되, 검증 범위는 개발 단계에 맞춰 나눴습니다. **MR에서는 Unit 위주로 빠르게 피드백**을 주고, Merge 후에는 운영과 유사한 환경에서 Unit·Integration을 함께 실행해 변경 영향을 확인하도록 구성했습니다.

결과

개발 단계별 자동 검증을 코드 리뷰와 배포 전 확인 절차에 정착시켰으며, 현재는 메인 솔루션의 **테스트 커버리지 60%를 목표로 범위를 확대**하고 있습니다.

60%	2단계	TestContainer
커버리지 목표	MR / Merge 후	격리 환경

도식 1 테스트는 언제, 얼마나 돌리는가?



자주 돌아야 하는 검사는 가볍게,
정확해야 하는 검사는
운영과 가까운 환경에서 합니다.

MR에서 무거운 테스트를 돌리면 결국 건너뛰게 됩니다.
단계를 나눈 이유가 여기 있습니다.

Junit5 TestContainer GitLab CI Jenkins

07 철도시설 성능평가 통합 시스템 ↗

한국전기철도협회 2023.04 – 현재 개발 · 운영

> 분석 쿼리를 33,600ms에서 444ms로 개선하고, 문서 생성과 무중단 배포 체계를 구축했습니다.

문제

법령에 따라 철도운영사의 시설 성능을 같은 기준으로 평가하는 시스템으로,
수백 장에 달하는 평가 결과를 PPT·Excel·PDF·한글로 제공해야 했습니다.
분석 API 응답에도 30초 이상 걸려 **평가 결과를 조회하고**
문서로 전달하는 과정을 함께 개선할 필요가 있었습니다.

판단

쿼리 실행 계획에서 인덱스를 활용하지 못하는 형태를 확인해 쿼리 구조와 인덱스부터
조정하고, 자주 조회되는 결과는 캐싱해 DB가 반복해서 처리하는 작업을 줄이기로 했습니다.

실행

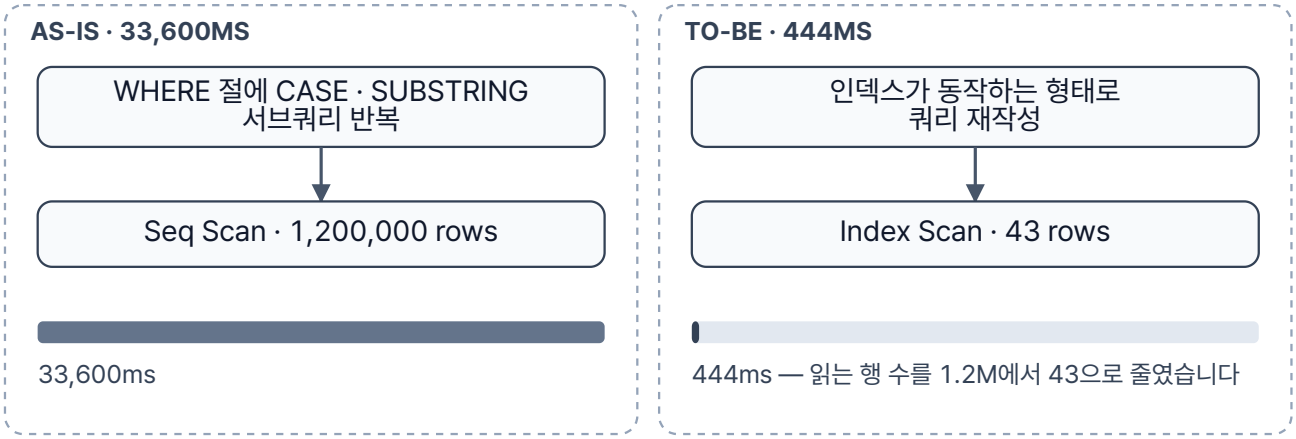
ClipReport 5.0 양식에 평가 데이터를 매핑해 여러 형식의 문서를 생성하고,
분석 쿼리의 서브쿼리와 WHERE 절 함수를 정리하면서 인덱스를 적용했습니다.
운영 환경을 AWS로 옮기는 과정에서는 Redis 캐시·공유 세션과
Nginx·Docker Blue/Green 배포를 함께 적용해 반복 조회의 DB
부하를 낮추고 배포 중에도 서비스를 유지하도록 구성했습니다.

결과

분석 쿼리를 **33,600ms에서 444ms로 줄여 약 75배**
개선했고, 평균 API 응답시간도 30ms 단축했습니다.
수백 장의 평가 문서는 5~30초 안에 생성할 수 있게 됐으며,
배포 중에도 서비스를 유지할 수 있는 운영 체계를 갖췄습니다.

33,600ms → 444ms	**5~30초**	**30ms↓**
분석 쿼리 · 약 75배	수백 장 문서 생성	평균 API 응답

도식 1 같은 질문인데 왜 33초와 0.4초로 갈렸는가?



같은 데이터에 대한 쿼리를 재작성하고 인덱스를 적용해 조회 시간을 33,600ms에서 444ms로 줄였습니다.

AWS Redis 쿼리 튜닝 Blue/Green ClipReport Nginx

08 피플 · 헌혈 매칭 플랫폼 ↗

피플 2022.02 – 2023.11 창업 · 개발 총괄 (BE · App)

> 환자 사연과 헌혈 참여를 연결하는 앱을 개발해, 700건 이상의 사연에 2,000건의 헌혈 응답을 모았습니다.

문제

코로나 시기 혈액 수급이 어려워지면서 수혈이 필요한 환자와 가족이 헌혈자를 직접 구해야 했지만, 모집은 커뮤니티 연결에 의존하고 있어 **헌혈자도 자신의 참여가 필요한 환자를 찾기 어려웠습니다.**

판단

환자는 필요한 헌혈자를 찾고 헌혈자는 참여할 사연을 고를 수 있도록 사연과 응답을 중심으로 설계하되, **특정 환자에게 참여가 쏠리지 않도록 기본 게시 기간을 3일**로 정했습니다. 일회성 방문에 그치지 않고 꾸준히 참여할 수 있도록 헌혈증 인증을 캘린더·뱃지·포인트 샵의 기록과 보상 흐름으로 연결했습니다.

실행

헌혈자가 사연을 보고 채팅으로 환자·보호자에게 직접 연락해 지정헌혈에 참여하는 흐름을 구현했습니다. 사연은 등록 후 3일이 지나면 자동 삭제하되, **작성자가 앱에 다시 접속해 게시 기간을 직접 연장**할 수 있도록 구성했습니다.

담당 역할

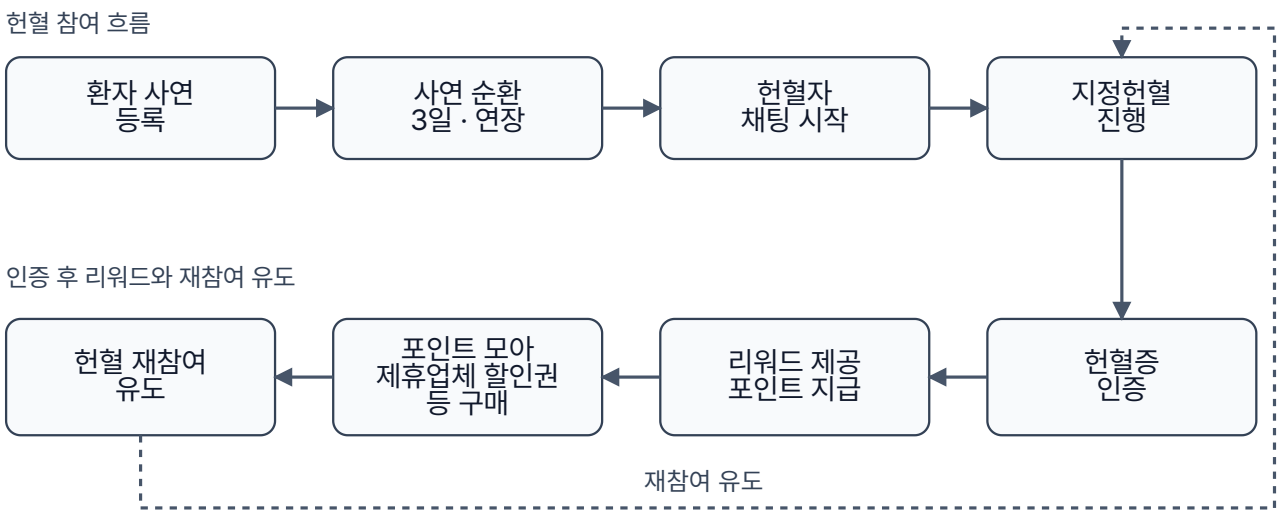
백엔드와 앱을 직접 개발하고, AWS 운영 비용을 관리했습니다.

결과

2024년 11월 기준 사용자 5,758명과 헌혈 참여 3,736회·지정헌혈 참여 1,250회를 기록했으며, **700건이 넘는 사연에 2,000건의 헌혈 응답**이 모였습니다. 2023년에는 예비사회적 기업으로 선정되었습니다.

5,758명	3,736회	1,250회
사용자 (2024.11)	헌혈 참여	지정헌혈 참여

도식 1 헌혈증 인증과 리워드는 어떻게 헌혈 재참여로 이어지는가?



사연은 기본 3일 뒤 자동으로 내려가며, 작성자가 앱에 다시 접속해 직접 연장합니다.
헌혈자는 사연을 보고 채팅을 시작해 환자·보호자에게 직접 연락하고 지정헌혈을 진행합니다.

헌혈증 인증 후 포인트를 지급하고, 모은 포인트로 제휴업체 할인권 등을 구매할 수 있도록 구성해 헌혈 재참여를 유도합니다.

헌혈 매칭 Flutter Spring Boot AWS

09 Mongle · 이미지 업로드·변환 파이프라인 ↗

6인 팀 · 사이드 프로젝트 2024.04 – 2024.05 BE 개발 총괄 · 기여도 90%

> 이미지 업로드·변환·캐시 갱신을 구현하고, 이미지의 서버 응답 대기 시간을 62.69ms에서 24.72ms로 줄였습니다.

문제

이전 프로젝트에서 큰 원본 이미지를 그대로 제공해 로딩이 느렸던 경험이 있었고, Mongle에서도 화면마다 필요한 이미지 크기가 달랐습니다.
여기에 백엔드가 파일을 받아 S3로 다시 보내는 중계 부담과 교체 후에도 CDN에 이전 이미지가 남는 문제가 있어, **업로드·이미지 제공·캐시 갱신을 함께 개선**할 필요가 있었습니다.

판단

여러 크기를 미리 저장하는 방식과 요청 시 변환하는 방식을 비교한 뒤, 원본은 S3에 두고 요청 파라미터에 맞춰 변환한 결과를 캐싱하도록 설계해 다양한 화면 크기에 대응했습니다.

실행

클라이언트가 Presigned URL로 S3에 직접 업로드하도록 연결해 백엔드의 파일 중계를 없애고,
조회 시에는 CloudFront·Lambda@Edge·Sharp로 너비·높이·포맷·품질을 조절했습니다.
이미지를 교체하면 S3 변경 이벤트를 받은 Lambda가 해당 경로의 CDN 캐시를 무효화해 이전 이미지가 계속 제공되지 않도록 했습니다.
업로드 완료 이벤트는 EventBridge·SQS를 거쳐 NestJS로 전달하고,
이벤트 검증과 이미지 정보의 DB 저장에 성공한 뒤에만 메시지를 삭제하도록 구성해 저장 실패 시 다시 처리할 수 있게 했습니다.

결과

리사이징·CDN 적용 전후 비교에서 **서버 응답 대기 시간은 62.69ms에서 24.72ms로, 콘텐츠 다운로드 시간은 2.10ms에서 0.82ms로 줄었습니다.**

구현 기록 ↗

62.69ms → 24.72ms	2.10ms → 0.82ms	S3 직접 업로드
서버 응답 대기 · 전후 비교	콘텐츠 다운로드 · 전후 비교	Presigned URL · 파일 중계 제거

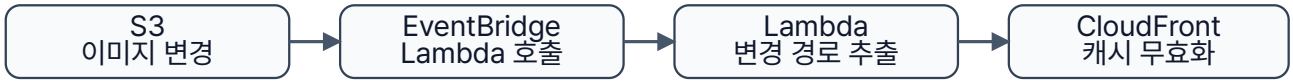
도식 1 파일을 중계하지 않고 업로드 완료를 어떻게 기록하는가?

업로드 · 완료 이벤트



파일은 클라이언트 → S3로 전송합니다. 서버는 이벤트 검증 → DB 저장 → 메시지 삭제 순서로 처리합니다.

이미지 교체 · 캐시 갱신

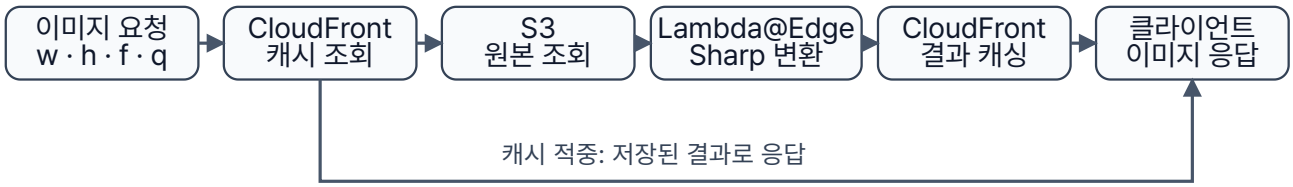


변경된 경로의 캐시를 무효화해, 이후 조회에서 갱신된 원본을 가져오도록 합니다.

파일 전송과 완료 정보 기록을 분리했습니다.
업로드 후 DB 반영은 NestJS 서버가 맡고, 이미지 교체는 캐시 갱신 흐름으로 처리합니다.

도식 2 같은 원본을 화면마다 다른 크기로 어떻게 제공하는가?

캐시 미적중: 원본 조회 → 요청별 변환 → 캐싱



첫 요청은 이미지 변환 시간이 들고, 같은 조건의 후속 요청은 캐시된 결과를 재사용합니다.
크기별 이미지를 미리 생성하는 대신, 다양한 화면 크기에 맞춘 요청 시 변환을 선택했습니다.

캐시 미적중과 적중 경로를 나눴습니다.
Sharp 변환은 Lambda@Edge의 원본 응답 단계에서 수행하고, 결과를 CloudFront에서 캐싱합니다.

S3 | Presigned URL | CloudFront | Lambda@Edge | Sharp | EventBridge | SQS | NestJS

03 런북

operational standards

배포·장애 복구·쿼리 개선·권한 관리를 팀 공통 절차로 표준화했습니다.

새 서비스 배포 온보딩

ArgoCD App of Apps

01 이미지를 빌드해 레지스트리에 푸시되는지 CI 로그로 확인한다.

02 App of Apps에 애플리케이션 매니페스트를 추가한다 (환경별 values 분리).

03 Image Updater가 새 태그를 감지하도록 규칙을 확인한다.

04 Sync 후 Pod 상태와 ReplicaSet이 기대값인지 확인한다.

05 HealthCheck · 알림 · 로그 수집이 붙었는지 확인하고 Teams 알림을 검증한다.

배포와 롤백

변경 이력은 Git에

01 헤더 기반 카나리 배포로 구성한 beta(스테이징) 환경에서 검증하고, Kiali에서 트래픽 흐름을 확인한다.

02 에러율·지연이 기준을 넘으면 Git에서 이전 revision으로 되돌린다 (수동 kubectl 금지).

03 롤백 후에도 알림과 메트릭이 정상인지 확인한다.

04 배포 기록은 Git 커밋과 ArgoCD 이력으로 남기고, 무엇이 문제였는지 한 줄로 기록한다.

DR 발동과 복구 검증

Route53 → SQS → KEDA

01 Route53 HealthCheck 실패 알림을 확인한다.

02 SQS 이벤트가 발행되었고 KEDA가 DR 클러스터의 Pod를 올렸는지 확인한다.

03 DB Replication 상태와 복구 시점(RPO)을 확인한다.

04 트래픽이 정상 리전으로 돌아왔는지, 지연이 기준 이내인지 측정한다.

05 실제 복구 시간을 기록하고 3분 목표를 넘겼다면 원인을 남긴다.

슬로우 쿼리 대응

실행 계획부터

01 대상 쿼리의 실행 계획을 확인한다 (full scan 여부, rows 추정치).

02 WHERE 절의 함수·CASE·SUBSTRING과 불필요한 서브쿼리를 제거해 인덱스가 동작하는 형태로 바꾼다.

03 필요한 인덱스를 설계·적용하고 실행 계획을 다시 비교한다.

04 반복 조회되는 데이터는 Look-Aside 캐싱 대상인지 검토한다.

05 개선 전후 시간을 기록한다 (예: 33,600ms → 444ms).

계정 · 권한 발급과 회수

IdP 계정 · Keycloak 권한

01 외부 IdP 계정 상태와 Keycloak에 연동된 계정의 소속·역할 속성을 확인한다.

02 접근이 필요한 시스템에 속성 기반으로 권한을 매핑한다.

03 로그인 및 주요 접근에 MFA가 요구되는지 확인한다.

04 퇴사·이동 시 외부 IdP 계정 상태와 연동 시스템의 권한·세션을 점검하고 잔여 접근이 없는지 확인한다.

05 변경 이력을 남겨 입사·퇴사 시 누락이 생기지 않게 한다.

04 스킬

실무에서 써 본 범위

강조된 항목은 실무에서 **설계와 운영까지** 맡아본 것입니다.

BACKEND

설계 · 운영까지

- Kotlin
- Spring Boot
- Spring Security
- Spring
- Hibernate
- Thymeleaf
- TypeScript
- NestJS
- JUnit 5

Java · QueryDSL · MyBatis · Spring Data JPA

DATA

운영 · 튜닝

- MariaDB
- MySQL
- PostgreSQL
- Redis

Oracle · ElastiCache · 실행 계획 · 인덱스 설계

INFRA · CLOUD

구축 · 운영

- Kubernetes
- Rancher
- Argo CD
- Istio
- Docker
- Longhorn
- AWS
- AWS Lambda
- Amazon RDS

KEDA · Gateway API · S3 · CloudFront · SQS · Route53 · Docker Swarm

AUTH · SECURITY

설계 · 구축

- Keycloak
- OpenID Connect

OAuth2 · ABAC · MFA · Private Subnet · Security Group · NACL

OBSERVABILITY

구축 · 운영

- Prometheus
- Grafana
- Fluent Bit
- Sentry

Kiali · CloudWatch · Micrometer

DELIVERY

자동화

- GitLab
- Jenkins
- GitHub Actions
- NGINX

Blue/Green · Canary

emibgo2@naver.com
© 2026 고지훈